

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
ESCOLA POLITÉCNICA

PROPOSTA DE TRABALHO

COE609 - 2026.1 - Ciência de Dados Aplicada ao Futebol

Alunos: Luiz Guilherme de Andrade Pires;
Pedro Eduardo Gonçalves;
João Pedro Sales.

Professores: Pedro Henrique Gonzalez Silva; Rafael Schneider.

1. TÍTULO

Modelo Preditivo de Sucesso de Contra-ataques no Futebol a partir do Estado do Jogo: incorporação de atributos físicos agregados por jogador como alternativa ao tracking contínuo.

2. ÊNFASE

Computação; Ciência de Dados; Aprendizado de Máquina; Sports Analytics.

3. TEMA

O tema do trabalho é o estudo da viabilidade de prever o sucesso de contra-ataques no futebol a partir do estado instantâneo do jogo no momento da recuperação da posse de bola. Pretende-se responder ao problema relacionado com a possibilidade de modelar a probabilidade de uma transição ofensiva resultar em finalização de qualidade utilizando, como variáveis explicativas, a configuração espacial dos jogadores no campo combinada a um perfil físico agregado de cada atleta. A hipótese inicial é que, se a configuração espaço-física do estado do jogo é suficientemente informativa, então é possível propor um modelo de classificação binária que estime essa probabilidade com poder preditivo significativo, mesmo sem o uso de dados de tracking contínuo de alta frequência. Desta forma, busca-se avaliar empiricamente se atributos físicos estáticos por jogador, construídos como prior, podem substituir as features físicas instantâneas tradicionalmente extraídas de sistemas de rastreamento óptico, ampliando a aplicabilidade prática da metodologia.

4. DELIMITAÇÃO

O objeto de estudo são as cadeias de posse caracterizadas como contra-ataques em partidas de futebol profissional. As cadeias serão extraídas a partir de dados de eventos e dados de posicionamento StatsBomb 360 disponibilizados publicamente. O modelo computacional está voltado à predição binária do desfecho da cadeia (sucesso versus não-sucesso), e não à modelagem da dinâmica completa do jogo, à identificação automática de padrões táticos ou ao processo decisório individual dos atletas. As features físicas dos jogadores serão obtidas a partir de bases públicas de atributos de videogame de simulação esportiva (Football Manager), tratadas como proxy estático da capacidade física do atleta no período correspondente.

5. LOCALIZAÇÃO

Os primeiros estudos quantitativos aplicados ao futebol datam do início do século XXI e enfatizavam métricas agregadas por partida, como posse de bola e número de finalizações. Com o advento dos dados de eventos comerciais (Opta, Wyscout, StatsBomb), tornou-se possível analisar ações individuais com precisão espacial, dando origem a modelos como Expected Goals (xG) e Expected Threat (xT). Mais recentemente, a disponibilização de dados de tracking — incluindo o produto StatsBomb 360 — permite incorporar a posição dos jogadores ao redor da bola no momento de cada evento, viabilizando análises mais ricas do contexto tático.

Este trabalho localiza-se neste último contexto, no campo conhecido como sports analytics aplicado ao futebol, e dialoga com uma linha de pesquisa específica e ativa: a predição de sucesso de transições ofensivas, recentemente consolidada na literatura sob a denominação xCounter.

6. JUSTIFICATIVA

O contra-ataque é uma das situações táticas de maior valor no futebol moderno, por explorar momentos de desorganização defensiva do adversário e gerar finalizações de alta qualidade por unidade de tempo. Apesar disso, o material didático abordado no curso de Introdução à Ciência de Dados Aplicada ao Futebol trata o tema de transição apenas de forma descritiva, por meio de mapas de recuperação e progressão e da discussão sobre defesa pós-perda, sem desenvolver um modelo preditivo dedicado.

Existem trabalhos publicados próximos ao tema proposto, com destaque para Biermann et al. (2023, 2024), que introduziram o framework xCounter, e Sahasrabudhe e Bekkers (2023), que aplicaram redes neurais em grafos sobre dados de tracking contínuo. Todos esses trabalhos, no entanto, dependem de dados de rastreamento óptico de alta frequência (10 Hz ou superior) para extrair velocidade e aceleração instantânea dos jogadores. Tal dado é caro, de cobertura limitada em ligas fora da elite europeia e raramente disponível em datasets públicos.

Neste sentido, o presente projeto é uma complementação dos estudos anteriores, buscando avançar na compreensão da modelagem de transições ofensivas a partir de fontes de dados mais acessíveis. Sua originalidade reside em avaliar empiricamente se atributos físicos agregados por jogador, obtidos de bases públicas de simulação esportiva, podem servir como prior estático e substituir, com perda controlada de poder preditivo, as features físicas instantâneas de tracking contínuo. Assim, a importância deste trabalho está relacionada com a possibilidade de aplicar a metodologia xCounter em contextos de dados limitados, ampliando seu uso prático para ligas e categorias sem cobertura de tracking óptico.

7. OBJETIVO

O objetivo geral é propor e avaliar um modelo computacional capaz de estimar a probabilidade de sucesso de um contra-ataque a partir do estado do jogo no momento da recuperação da posse, incorporando features espaciais extraídas de freeze frames StatsBomb 360 e features físicas agregadas por jogador. Desta forma, têm-se como objetivos específicos:

- (1) definir operacionalmente os critérios que caracterizam uma cadeia de posse como contra-ataque e que caracterizam essa cadeia como bem-sucedida, garantindo reprodutibilidade da análise;
- (2) construir um pipeline de extração de features espaciais (distância gol-defensor mais próximo, distância gol-atacante mais avançado, superioridade numérica, compactação defensiva, entre outras) a partir dos freeze frames disponibilizados pela StatsBomb 360;
- (3) integrar uma base externa de atributos físicos por jogador (Football Manager, com temporada compatível com o dataset esportivo escolhido), gerando um perfil físico estático por atleta;

- (4) treinar e comparar três modelos de classificação binária — regressão logística com features espaciais apenas, regressão logística com features espaciais e físicas, e XGBoost com todas as features —, avaliando-os por AUC, Brier score e calibração;
- (5) conduzir análise de ablação sobre os grupos de features físicas, identificando quais atributos contribuem mais para o poder preditivo do modelo;
- (6) interpretar os resultados via coeficientes da regressão logística e SHAP values do modelo XGBoost, traduzindo as descobertas em insights táticos.

8. METODOLOGIA

Este trabalho utiliza a metodologia de classificação supervisionada para modelar a probabilidade de sucesso de contra-ataques. A abordagem se inspira diretamente no framework de modelagem de probabilidade de eventos por meio de features posicionais, conforme apresentado por Fernández et al. (2019) e aplicado ao xG na disciplina, adaptando-o para o problema da transição ofensiva.

Inicialmente, será operacionalizada a definição de contra-ataque. Uma cadeia de posse é classificada como contra-ataque se atende a três critérios: inicia-se em recuperação de bola no campo defensivo ou meio-campo defensivo da equipe que recupera; apresenta progressão vertical mínima em curto intervalo de tempo (parametrizado em metros e segundos, com análise de sensibilidade); e envolve número limitado de eventos até o desfecho. O sucesso é definido como a finalização da cadeia em chute com xG acima de um limiar pré-estabelecido, utilizando o modelo de xG construído na Aula 2 da disciplina como filtro de qualidade.

Em seguida, para cada cadeia identificada como contra-ataque, será recuperado o freeze frame StatsBomb 360 correspondente ao evento de início da cadeia. Deste frame serão extraídas features espaciais que descrevem a configuração de campo no instante da recuperação. Paralelamente, a identidade dos jogadores envolvidos (atacante mais avançado e defensor mais próximo) será cruzada com a base de atributos físicos do Football Manager, garantindo compatibilidade temporal entre a temporada do dataset esportivo e a versão do videogame.

Os modelos serão treinados com divisão estratificada em treino, validação e teste, com cuidado explícito para evitar vazamento de dados (jogos de teste não compartilhados com o treino, e atributos físicos calculados apenas com informação anterior aos jogos de teste). A

avaliação seguirá o protocolo da Aula 2 da disciplina, utilizando AUC, Brier score e curvas de calibração.

A análise interpretativa será conduzida por meio dos coeficientes da regressão logística e dos SHAP values do modelo XGBoost, com o objetivo de identificar quais features contribuem mais para a predição. A análise de ablação avaliará especificamente o ganho marginal das features físicas sobre o baseline puramente espacial.

As bases de dados utilizadas são todas de domínio público: dados de eventos e StatsBomb 360 são acessados via biblioteca mplsoccer; atributos do Football Manager são obtidos por meio de dumps disponíveis na plataforma Kaggle. O ambiente de desenvolvimento é Python com Jupyter Notebook, conforme padrão da disciplina.

9. MATERIAIS

Os recursos previstos para a execução do projeto são listados a seguir:

1. Computadores pessoais dos membros do grupo, com capacidade suficiente para treinamento de modelos;
2. Linguagem Python 3 e ambiente Jupyter Notebook, ambos open source;
3. Bibliotecas Python de uso livre: pandas, numpy, matplotlib, mplsoccer, scipy, statsmodels, scikit-learn, xgboost, shap;
4. Dados de eventos e StatsBomb 360, disponibilizados publicamente via biblioteca mplsoccer;
5. Base de atributos de jogadores do Football Manager, obtida via dumps públicos disponíveis na plataforma Kaggle (verificação de compatibilidade de temporada com o dataset esportivo escolhido);
6. Material didático da disciplina Introdução à Ciência de Dados Aplicada ao Futebol (notebooks e slides) como referência metodológica.

10. CRONOGRAMA

As fases de execução do projeto estão organizadas conforme descrição abaixo, com duração total prevista compatível com o calendário da disciplina.

Fase 1: Revisão bibliográfica aprofundada dos trabalhos correlatos (Biermann et al., Sahasrabudhe e Bekkers, Bauer e Anzer) e definição final dos critérios operacionais de contra-ataque e sucesso.

Fase 2: Levantamento e validação das bases de dados: identificação das competições StatsBomb com cobertura 360 disponível, verificação da temporada compatível na base Football Manager via Kaggle, e prova de conceito do alinhamento evento-tracking.

Fase 3: Construção do pipeline de extração de cadeias de contra-ataque a partir de possession_chain, e do pipeline de extração de features espaciais a partir dos freeze frames 360.

Fase 4: Integração da base de atributos físicos do Football Manager via cruzamento por identidade do jogador, e construção do dataset final de treinamento.

Fase 5: Treinamento dos modelos comparativos (logística baseline, logística completa, XGBoost), avaliação por AUC, Brier score e calibração, e análise de ablação dos grupos de features físicas.

Fase 6: Análise interpretativa dos resultados (coeficientes e SHAP values), redação do relatório final e preparação da apresentação.

Referências Bibliográficas

- [1] BIERMANN, H.; KOMITOVA, R.; RAABE, D.; MEMMERT, D. "Towards Expected Counter — Using Comprehensible Features to Predict Counterattacks". MathSport International Conference, 2023.
- [2] BIERMANN, H.; et al. "Quantification of Turnover Danger with xCounter". International Journal of Computer Science in Sport, 2024.
- [3] SAHASRABUDHE, A.; BEKKERS, J. "A Graph Neural Network deep-dive into successful counterattacks". MIT Sloan Sports Analytics Conference, 2023.
- [4] BAUER, P.; ANZER, G. "Data-driven detection of counterpressing in professional football". Data Mining and Knowledge Discovery, 2021.
- [5] FERNÁNDEZ, J.; BORNN, L.; CERVONE, D. "Decomposing the Immeasurable Sport: A deep learning expected possession value framework for soccer". MIT Sloan Sports Analytics Conference, 2019.
- [6] SINGH, K. "Introducing Expected Threat (xT)". Disponível em: <https://karun.in/blog/expected-threat.html>, 2019.

[7] GONZALEZ, P. H.; SCHNEIDER, R. Material didático da disciplina "Ciência de Dados Aplicada ao Futebol". Universidade Federal do Rio de Janeiro, 2026.

Rio de Janeiro, 3 de Maio de 2026.